



SAKARYA
ÜNİVERSİTESİ

BSM 310 YAPAY ZEKA

CEMİL ÖZ, İSMAİL ÖZTEL

~ KONVOLÜSYONEL SİNİR AĞLARI~


KONULAR

- Derin öğrenme tanımı
- Sayısal görüntü işlemeye giriş
- Derin ağlarda veri kümesi
- Konvolüsyonel sinir ağları
- Konvolüsyon, Havuzlama, ReLU katmanları
- Derin ağ eğitiminde karşılaşılabilecek sorunlar
- Transfer öğrenme
- Veri çoklama


Transfer Öğrenme

- Problemler için yeni bir ağ tasarlanıp eğitim yapılabileceği gibi daha önce farklı bir problem için tasarlanan bir ağ da yeni bir problemin çözümünde kullanılabilir. Bu işlem transfer öğrenme olarak adlandırılabilir.
- Örneğin 1000 tane nesneyi sınıflandırmak için tasarlanan ve oldukça yüksek başarımlar veren AlexNet mimarisi yüz ifadesi tespiti için kullanılabilir ve yine başarılı sonuç üretebilir.
- Transfer öğrenme uygulamak için ağın ilk katmanları sabit bırakılıp son katmanları yeni problemi çözecek şekilde yeniden eğitim yapılarak güncellenir.

Transfer Öğrenme



Transfer öğrenme adımları



Alexnet mimarisinin transfer öğrenme için güncellenmesi

Transfer Öğrenme

- Genellikle, ağın ilk katmanları kenar bulma, renk belirleme, vb. gibi genel görüntü işleme işlemlerini yapar.
 - Yüz ifadesi tespiti için de, nesne tanıma için de, bölütleme işlemleri için de, diğer görüntü sınıflandırma işlemleri için de konvolüsyonel sinir ağların ilk katmanlarında yapılan işlemler benzerdir.
 - Bu nedenle transfer öğrenme oldukça kullanışlı bir yaklaşımdır.

Transfer Öğrenme


- Transfer öğrenmenin diğer faydaları aşağıda sıralanmıştır.
 - Bazı modellerin eğitimi, standart bilgisayar işlemcileri ile mümkün olmayıp grafik işlemcileriyle eğitmeye ihtiyaç duyar ve bazı eğitimler çok uzun sürer. Bu eğitim sonucunda oluşan ağ modeli farklı amaçlar için de kullanma açısından transfer öğrenme oldukça avantajlıdır.
 - Elimizde çok fazla veri yoksa dahi, transfer öğrenme sayesinde, daha önce milyonlarca veri ile eğitilen bir ağı kullanarak kendi problemimize başarılı sonuç üretebiliriz.
 - Transfer öğrenme sayesinde problemlere daha hızlı çözüm bulabiliriz. Zaman tasarrufu sağlar.

Veri Artırma (Data Augmentation)

- Derin öğrenmede veri sayısının çok olması ağın performansını önemli ölçüde artırır.
- Veri setinin küçük olduğu durumlarda başarıyı artırmak için veri çoklama uygulanabilir.
- Veri setindeki verilerin çeşitli işlemlerle çoklanarak veri sayısının artırılmasına veri çoklama denir.
- Veri azlığından dolayı sürekli aynı verilerle eğitim sonucunda ezberleme sorununun ortaya çıkabileceğini öğrenmiştik. Veri artırma ile ezberleme probleminin de önüne geçilmiş olur.

Veri Artırma (Data Augmentation)

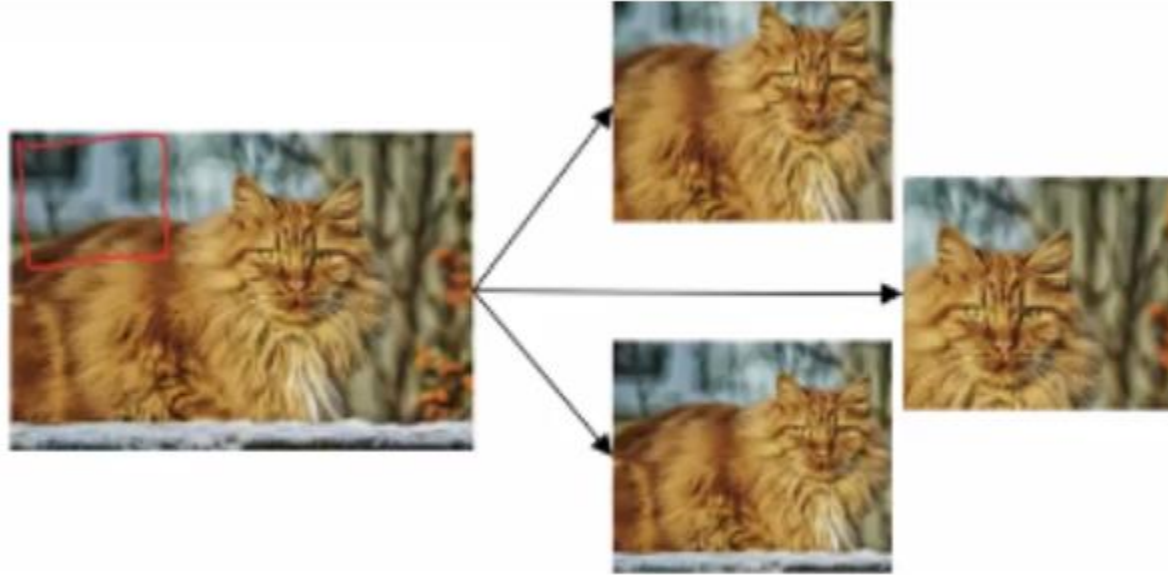
- Görüntünün eksenlere göre simetrilerinin alınması.



<https://medium.com/@ayyucekizrak/deri%CC%87ne-daha-deri%CC%87ne-evri%C5%9Fimli-sinir-a%C4%9Flar%C4%B1-2813a2c8b2a9>

Veri Artırma (Data Augmentation)

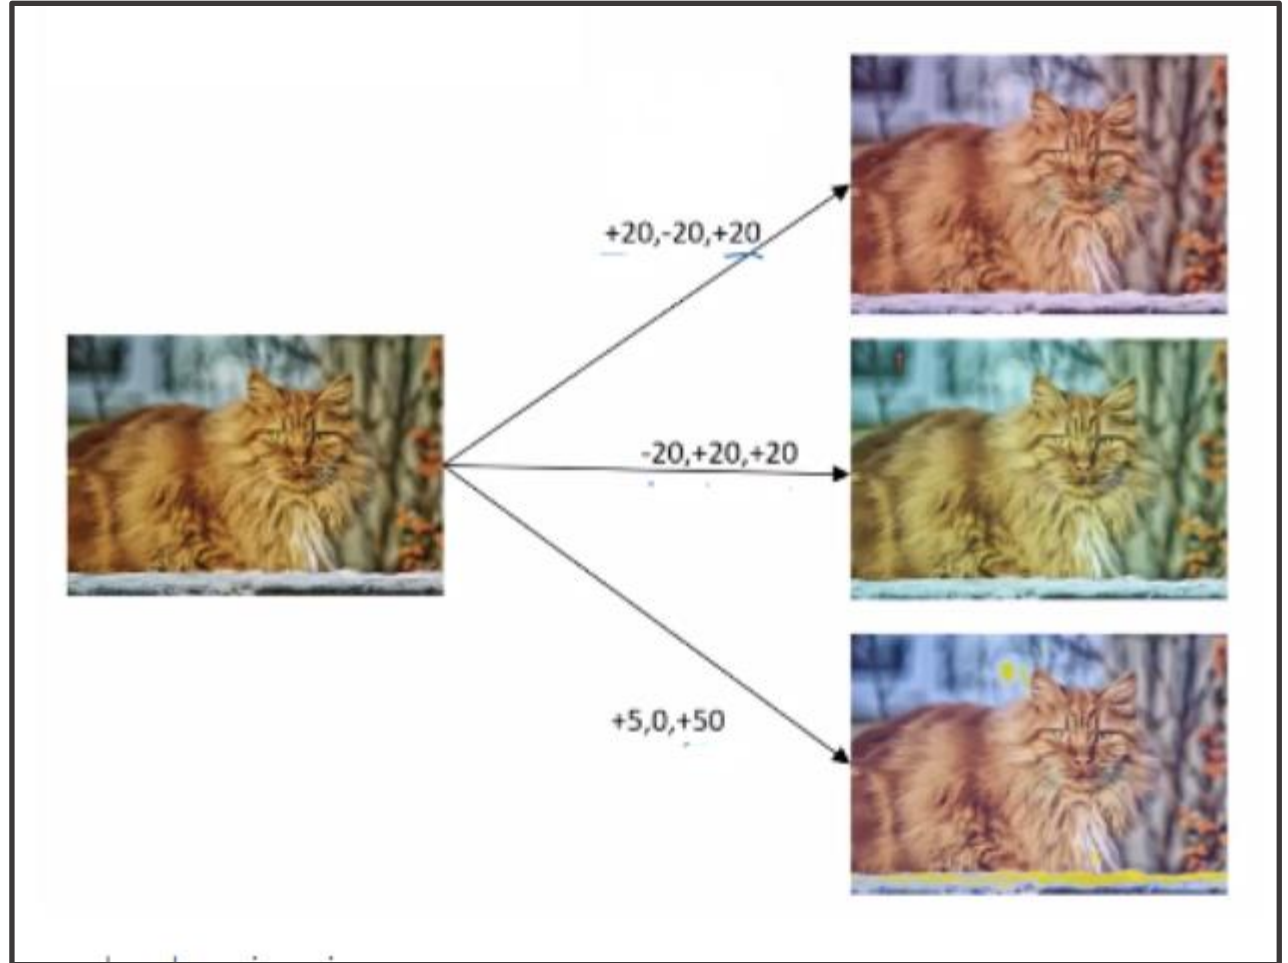
- Görüntüden bir parçanın kesilip alınması



<https://medium.com/@ayyucekizrak/deri%CC%87ne-daha-deri%CC%87ne-evri%C5%9Fimli-sinir-a%C4%9Flar%C4%B1-2813a2c8b2a9>

Veri Artırma (Data Augmentation)

- Görüntünün renk oranlarının değiştirilmesi



<https://medium.com/@ayyucekizrak/deri%CC%87ne-daha-deri%CC%87ne-evri%C5%9Fimli-sinir-a%C4%9Flar%C4%B1-2813a2c8b2a9>

Değerlendirme metrikleri

- Yapay zeka problemlerinde sonuçları farklı metrikler kullanarak değerlendirilebilir.
- Bu metriklerden bazıları:
 - Accuracy (acc)
 - Precision
 - Recall (sensitivity)
 - Specificity
 - F1 score

Değerlendirme metrikleri

- Karmaşıklık matrisi: Karmaşıklık matrisi; bir yaklaşımın girişlerini analiz ederek, bir test kümesindeki ayrıntılı sınıflandırma sonuçlarının elde edilmesini sağlayan bir tablodur.

Gerçek \ Tahmin	pozitif	negatif
	pozitif	negatif
pozitif	TP	FN
negatif	FP	TN

Değerlendirme metrikleri

- Örnek:
 - 100 resim var, bazılarında araba var, bazılarında yok.
 - Görev: Araba/araba değil sınıflandırması (ikili sınıflandırma)
 - Karmaşıklık matrisi aşağıda verilmiştir.

Tahmin Gerçek	araba	değil
	araba	değil
araba	45	18
değil	12	25

Değerlendirme metrikleri


Tahmin \ Gerçek	araba	değil
	araba	değil
araba	TP=45	FN=18
değil	FP=12	TN=25

- Örnek:
 - 100 resim var, bazılarında araba var, bazılarında yok.
 - Görev: Araba/araba değil sınıflandırması (ikili sınıflandırma)
 - Karmaşıklık matrisi aşağıda verilmiştir.

- $$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} = \frac{\text{doğru tahminler}}{\text{tüm tahminler}} = \frac{\text{doğru tahminler}}{\text{örnek sayısı}}$$

Değerlendirme metrikleri

- $$\text{Precision} = \frac{TP}{TP+FP} = \frac{\text{pozitif doğru tahminler}}{\text{pozitif tüm tahminler}}$$
- Yanlış pozitiflerin kritik olduğu durumlarda önemlidir.
 - Örneğin: spam e-postaları filtrelenirken (spam pozitif sınıftır, spam olmayan:negative), spam olmayan bir e-posta yanlışlıkla spam olarak işaretlenmemelidir.
 - Bu durumda FP küçük olmalıdır, bu nedenle precision yüksek olacaktır.



<https://towardsdatascience.com/logic-and-implementation-of-a-spam-filter-machine-learning-algorithm-a508fb9547bd>

Değerlendirme metrikleri

- $\text{Recall} = \frac{TP}{TP+FN} = \frac{\text{pozitif doğru tahminler}}{\text{setteki tüm pozitif örnekler}}$
- Doğru tahmin edilen pozitif gözlemlerin tüm gerçek pozitiflere oranını ifade eder.
 - Örnek: Hastalara bir hastalık teşhisi koyarken, gerçekten hastalığı olan birine sağlıklı teşhisi konmamalıdır, recall değeri yüksek olmalıdır.
 - FN değeri küçükse, recall yüksek olacaktır.

Değerlendirme metrikleri

- $\text{Specificity} = \frac{TN}{TN+FP} = \frac{\text{negatif doğru tahminler}}{\text{setteki tüm negatif örnekler}}$
- Tüm gerçek negatiflerden kaç tane negatif tahmin yapıldığının ölçüsüdür.
 - Örnek: yanlış pozitif sonuç hasta için gereksiz tedaviye veya kaygıya yol açabilir.
 - Bu tür bir sorun için specificity değeri yüksek olmalıdır.